

CoachAI

Avaliação Automática da Técnica de Exercícios com Human Pose Estimation On-Device

Relatório Final

Autor: Afonso Silva AL82140

Orientador: António Sousa

Coorientador: Vítor Filipe

Curso: Licenciatura em Engenharia Informática

Universidade de Trás-os-Montes e Alto Douro

2025/2026

1. Introdução

O aumento da utilização de tecnologias de Inteligência Artificial no contexto do fitness e da análise biomecânica tem permitido o desenvolvimento de soluções capazes de auxiliar utilizadores durante a execução de exercícios físicos. A análise automática da postura corporal através de Human Pose Estimation (HPE) tornou-se uma área de grande interesse devido à possibilidade de fornecer feedback corretivo em tempo real sem necessidade de sensores especializados.

O projeto CoachAI surge com o objetivo de desenvolver uma aplicação mobile capaz de analisar automaticamente exercícios físicos utilizando apenas a câmara de um smartphone. A aplicação recorre a técnicas de visão por computador e Human Pose Estimation para identificar articulações do corpo, calcular métricas biomecânicas e fornecer feedback visual ao utilizador.

O sistema foi desenvolvido com foco em processamento on-device (on-device), garantindo maior privacidade dos dados e reduzindo dependências de serviços cloud. O projeto centra-se principalmente em exercícios de força e mobilidade, permitindo futuramente a expansão para diferentes tipos de treino.

As principais contribuições deste projeto incluem o desenvolvimento de uma aplicação Android para Human Pose Estimation em tempo real, a integração do modelo MediaPipe Pose Landmarker para execução totalmente on-device, a implementação de um sistema de feedback automático baseado na qualidade da captura e a realização de uma avaliação experimental comparando diferentes abordagens de deteção de pose humana. O projeto demonstra a viabilidade da utilização de técnicas de Visão por Computador em dispositivos móveis para apoio à análise de exercícios físicos.

2. Human Pose Estimation e Trabalhos Relacionados

A Human Pose Estimation (HPE) consiste na identificação automática dos principais pontos anatómicos do corpo humano a partir de imagens ou vídeo. Estes pontos, designados por landmarks, permitem reconstruir a postura corporal e calcular métricas biomecânicas relevantes para análise de movimento. Nos últimos anos surgiram diversos modelos de HPE capazes de executar em tempo real em dispositivos móveis. Entre os mais conhecidos encontram-se o MediaPipe Pose, MoveNet, YOLO Pose, RTMPose e ViTPose. Estas soluções diferem em precisão, velocidade de processamento e requisitos computacionais.

A Human Pose Estimation tem sido aplicada em diversas áreas, incluindo fitness, fisioterapia, reabilitação, monitorização desportiva e análise biomecânica. Sistemas como o OpenCap e outras plataformas de avaliação de movimento demonstram o potencial desta tecnologia para fornecer feedback automático sem necessidade de sensores especializados.

Devido à necessidade de processamento em tempo real e execução on-device em dispositivos Android, o presente projeto adotou o MediaPipe Pose Landmarker como solução principal para deteção da pose humana.

Foram analisados diversos trabalhos relacionados com avaliação de exercícios físicos através de Human Pose Estimation, incluindo sistemas de correção postural, treinadores virtuais baseados em Inteligência Artificial e plataformas de análise biomecânica como OpenCap, LiftMate e MobiPhysio. Estes trabalhos demonstram o potencial da utilização de estimativa de pose para monitorização e avaliação automática do movimento humano.

3. Objetivos do Projeto

Os principais objetivos definidos para o projeto foram:

- Desenvolver uma aplicação Android para detecção de pose humana
- Implementar análise automática de exercícios físicos
- Calcular métricas biomecânicas relevantes
- Fornecer feedback corretivo em tempo real
- Garantir processamento on-device on-device
- Comparar diferentes modelos de Human Pose Estimation
- Avaliar desempenho em FPS e precisão
- Criar uma interface intuitiva para demonstração do sistema

Segundo a proposta oficial do projeto, os principais requisitos incluíam cálculo de ângulos articulares, análise de amplitude de movimento, contagem de repetições e comparação de modelos HPE.

4. Tecnologias Utilizadas

Durante o desenvolvimento do projeto foram utilizadas várias tecnologias e bibliotecas:

Tecnologia	Função
Kotlin	Desenvolvimento Android
Android Studio	Ambiente de desenvolvimento
CameraX	Captura de vídeo em tempo real
MediaPipe Tasks Vision	Human Pose Estimation
Pose Landmarker	Deteção de landmarks corporais
Python	Scripts de análise e comparação
OpenCV	Processamento de vídeo
YOLO Pose	Comparação de modelos
CSV	Armazenamento de resultados

5. Arquitetura Geral da Aplicação

A aplicação foi estruturada de forma modular, separando os diferentes componentes responsáveis pelo processamento de imagem, detecção de pose e apresentação visual.

A arquitetura principal inclui os seguintes módulos:

- MainActivity
- RealTimeActivity
- PoseEstimator.kt
- PoseOverlayView
- PoseDrawer
- RealTimeFeedbackAnalyzer
- VideoFrameExtractor

O fluxo geral da aplicação segue os seguintes passos: captura de vídeo através da câmera ou seleção de vídeo; extração de frames; processamento dos frames pelo modelo de pose; obtenção dos landmarks corporais; cálculo de métricas biomecânicas; geração de feedback em tempo real; e apresentação visual do esqueleto corporal.




Figura 1 – Exemplo de funcionamento da aplicação CoachAI.

6. Desenvolvimento Inicial da Aplicação

O desenvolvimento da aplicação iniciou-se com a criação da estrutura base necessária para suportar a captura e análise de vídeo em dispositivos Android. Foram integrados componentes responsáveis pela gestão da câmara, seleção de vídeos, reprodução multimédia e apresentação gráfica dos resultados. Para permitir a análise de exercícios previamente gravados, foi implementado um mecanismo de processamento de vídeo baseado na extração individual de frames. Esta abordagem possibilitou a execução de testes controlados e a análise detalhada do comportamento dos modelos de Human Pose Estimation ao longo do tempo.

7. Integração do MediaPipe Pose Landmarker

Uma das fases mais importantes do projeto foi a integração do sistema de Human Pose Estimation utilizando a framework MediaPipe Tasks. Ao contrário da abordagem clássica baseada em `mp.solutions.pose`, o projeto utilizou a API moderna Pose Landmarker através do modelo `pose_landmarker_full.task`, integrado on-devicemente na aplicação Android para processamento totalmente on-device.

7.1 Configuração do Projeto

A integração do MediaPipe Pose Landmarker exigiu a configuração de dependências específicas e a preparação do ambiente Android para suportar a execução do modelo de Human Pose Estimation. O modelo foi disponibilizado localmente através da pasta `assets`, permitindo processamento totalmente on-device.

7.2 Implementação do PoseEstimator

A classe `PoseEstimator.kt` foi desenvolvida para centralizar o carregamento do modelo, a execução da inferência e a gestão dos landmarks corporais obtidos a partir das imagens processadas.

7.3 Desenho do Esqueleto Corporal

De forma a facilitar a interpretação visual dos resultados, foi desenvolvido um sistema gráfico capaz de representar os landmarks corporais e as ligações anatómicas correspondentes através de um overlay sobre a imagem processada.

7.4 Processamento em Tempo Real

Uma das principais vantagens da solução utilizada foi a capacidade de executar em tempo real diretamente no smartphone. Os testes realizados demonstraram boa fluidez, baixa latência e desempenho adequado para dispositivos móveis. O processamento on-device também garante maior privacidade, menor dependência de internet e menor tempo de resposta.

A escolha do MediaPipe Pose Landmarker deveu-se principalmente à sua otimização para dispositivos móveis, elevada taxa de processamento, facilidade de integração com Android e capacidade de execução totalmente on-device. Estas características tornam o modelo particularmente adequado para aplicações que exigem feedback em tempo real e baixa latência.

7.5 Problemas Encontrados

Durante a integração surgiram vários problemas técnicos. O MediaPipe exigia imagens no formato `ARGB_8888`, originando crashes iniciais. Ocorreram também erros relacionados com imports e versões incompatíveis. Foi necessário otimizar a resolução dos frames, frequência de processamento e utilização de memória. O modelo apresentava ainda algumas dificuldades em diferenciar utilizadores de costas para a câmara.

8. Processamento de Vídeo e Extração de Frames

Posteriormente foi implementado o processamento de vídeos previamente gravados, permitindo analisar exercícios físicos sem necessidade de utilização da câmara em tempo real. Os vídeos selecionados pelo utilizador são divididos em frames individuais, que são posteriormente processados pelo modelo de Human Pose Estimation.

Para cada frame são identificados os principais landmarks corporais e desenhado o respetivo esqueleto humano sobre a imagem original. Esta funcionalidade permitiu realizar testes repetíveis sobre os mesmos vídeos, facilitando a comparação entre diferentes modelos de deteção de pose.

Foram utilizados vídeos contendo diferentes exercícios físicos e perspetivas de gravação, permitindo avaliar a robustez da deteção e o desempenho dos modelos em diferentes condições. Esta componente revelou-se fundamental para a validação experimental do sistema e para a realização de análises biomecânicas baseadas nos landmarks obtidos.




Figura 2 – Exemplos de frames processados pelo sistema com deteção dos landmarks corporais e desenho do esqueleto humano.

9. Sistema de Feedback em Tempo Real

Foi desenvolvido um sistema de feedback automático denominado RealTimeFeedbackAnalyzer, responsável por avaliar a qualidade da captura antes da execução da análise de pose. O objetivo principal consiste em garantir condições adequadas para a detecção correta dos landmarks corporais. O sistema verifica diferentes aspetos da imagem, incluindo iluminação, enquadramento, visibilidade do corpo, distância à câmara e orientação do utilizador. Sempre que é identificada uma situação inadequada, é apresentada uma mensagem corretiva em tempo real. Entre as mensagens implementadas encontram-se indicações como "Ambiente demasiado escuro", "Corpo pouco visível", "Aproxima-te da câmara" e "Coloca-te de frente para a câmara". Esta funcionalidade contribui para aumentar a robustez da aplicação, reduzindo falhas de deteção causadas por condições inadequadas de captura.




Figura 3 – Exemplos das mensagens de feedback geradas automaticamente pelo sistema durante a captura em tempo real.

10. Comparação de Modelos de Human Pose Estimation

Foi também realizada uma fase experimental de comparação entre diferentes modelos de Human Pose Estimation (HPE). Inicialmente, pretendia-se comparar o MediaPipe Pose Landmarker com modelos como YOLO Pose, RTMPose e ViTPose. No entanto, devido a problemas de compatibilidade, erros de importação e conflitos de versões entre dependências necessárias para o RTMPose e o ViTPose, não foi possível concluir a integração destes dois modelos no ambiente de testes. Assim, os testes experimentais realizados focaram-se principalmente no MediaPipe Pose Landmarker e no YOLO Pose, utilizando vídeos de exercícios físicos processados através de scripts Python. Foram avaliadas métricas como FPS médio, estabilidade, desempenho em dispositivos móveis e robustez visual. Os resultados obtidos demonstraram que o modelo do MediaPipe apresentou melhor desempenho para utilização mobile em tempo real.

11. Metodologia Experimental

Foram utilizados três vídeos de exercícios físicos para validação experimental do sistema: deslizamento_escapular, deslizamento_escapular_lat e polichinelo_adaptado. Os vídeos foram processados utilizando scripts Python desenvolvidos para análise dos modelos de Human Pose Estimation. Para a comparação entre modelos foram avaliados o número de frames processados, a taxa média de processamento (FPS) e a qualidade visual da detecção. Adicionalmente, foi realizada uma análise biomecânica utilizando os landmarks produzidos pelo MediaPipe Pose Landmarker, permitindo calcular os ângulos articulares do cotovelo (ombro-cotovelo-pulso) ao longo do movimento do exercício deslizamento escapular.

12. Testes e Resultados Obtidos

Durante a fase de testes foram utilizados vários vídeos de exercícios físicos para validar o funcionamento da aplicação e avaliar o desempenho dos modelos de Human Pose Estimation. Os testes permitiram verificar a capacidade de detecção dos landmarks corporais, a estabilidade da pose ao longo do tempo e o desempenho em termos de velocidade de processamento.

Foram realizadas experiências utilizando o MediaPipe Pose Landmarker e o YOLO Pose, recorrendo a scripts desenvolvidos em Python para processar os vídeos e recolher métricas de desempenho. Entre os principais indicadores analisados destacam-se o número total de frames processados, o FPS médio obtido por cada modelo e a robustez visual da detecção em diferentes condições de utilização.

Os resultados demonstraram que ambos os modelos foram capazes de identificar corretamente as principais articulações do corpo. No entanto, o MediaPipe apresentou uma taxa de processamento significativamente superior à do YOLO Pose, atingindo valores próximos dos 70 a 75 FPS nos vídeos analisados, enquanto o YOLO Pose apresentou valores próximos dos 35 FPS.

Para além do melhor desempenho em FPS, o MediaPipe revelou também maior adequação para utilização em dispositivos móveis, devido à sua integração otimizada para processamento on-device e menor exigência computacional. Estas características tornam-no mais apropriado para aplicações de feedback em tempo real, onde a fluidez e a baixa latência são fatores fundamentais.

Adicionalmente, foi realizada uma análise da variação angular do cotovelo durante a execução do exercício deslizamento escapular. Os ângulos foram calculados utilizando os landmarks do ombro, cotovelo e pulso detetados pelo modelo MediaPipe. Os resultados evidenciaram uma variação consistente ao longo das repetições do movimento, permitindo identificar os momentos de maior flexão e extensão articular. Esta experiência demonstra que os landmarks obtidos pelo sistema podem ser utilizados para extração de métricas biomecânicas relevantes para análise de exercícios físicos.




Figura 4 – Variação angular do cotovelo (ombro-cotovelo-pulso) durante a execução do exercício deslizamento escapular.

13. Discussão dos Resultados

Os resultados obtidos demonstram que o MediaPipe Pose Landmarker apresentou melhor desempenho global para o contexto do projeto. A sua taxa de processamento superior permitiu obter maior fluidez e menor latência durante a análise em tempo real.

Embora o YOLO Pose tenha apresentado resultados visualmente satisfatórios na detecção da pose, os valores de FPS observados foram significativamente inferiores, tornando a sua utilização menos adequada para aplicações móveis que exigem resposta imediata ao utilizador.

A execução totalmente on-device constituiu igualmente uma vantagem importante, garantindo maior privacidade dos dados e reduzindo a dependência de serviços externos.

Uma das principais limitações da avaliação experimental foi a impossibilidade de testar os modelos RTMPose e ViTPose devido a incompatibilidades entre dependências e versões das bibliotecas necessárias para a sua execução.

A análise angular realizada demonstra igualmente o potencial da Human Pose Estimation para aplicações biomecânicas. A partir dos landmarks corporais foi possível calcular automaticamente ângulos articulares sem recurso a sensores externos ou sistemas de captura de movimento especializados. Este resultado está alinhado com trabalhos recentes da literatura que utilizam estimativa de pose para avaliação técnica de exercícios físicos e reabilitação.

14. Problemas Encontrados e Soluções Aplicadas

Problema	Solução
Crash ARGB_8888	Conversão correta do Bitmap
Imports MediaPipe	Atualização de dependências
Baixo FPS	Redução de resolução
Overlay desalinhado	Ajuste de coordenadas
Deteção incompleta	Melhor iluminação
Erros em emulador	Testes em dispositivo real

15. Limitações e Trabalho Futuro

Apesar dos resultados positivos obtidos, o projeto apresenta algumas limitações. A avaliação experimental incidiu principalmente sobre métricas de desempenho computacional, nomeadamente FPS e observação visual da qualidade da detecção.

Não foi possível realizar uma avaliação quantitativa da precisão dos landmarks utilizando métricas como Mean Absolute Error (MAE) ou Percentage of Correct Keypoints (PCK), previstas inicialmente na proposta do projeto.

Como trabalho futuro pretende-se expandir o sistema para novos exercícios físicos, implementar cálculo automático de ângulos articulares, contagem de repetições, avaliação quantitativa da precisão dos modelos e personalização do feedback fornecido ao utilizador.

16. Conclusão

O projeto CoachAI permitiu explorar técnicas modernas de Visão por Computador e Inteligência Artificial aplicadas ao contexto do fitness e da análise biomecânica. A integração do modelo `pose_landmarker_full.task` demonstrou que é possível executar Human Pose Estimation em tempo real diretamente num smartphone, com desempenho adequado e processamento totalmente on-device, sem necessidade de recorrer a serviços cloud.

Ao longo do desenvolvimento foram implementadas diferentes funcionalidades relacionadas com captura de vídeo, processamento de imagem, deteção de pose humana, desenho do esqueleto corporal e geração de feedback em tempo real. Estas componentes permitiram construir um protótipo funcional capaz de analisar o utilizador através da câmara do dispositivo e fornecer indicações que contribuem para melhorar a qualidade da captura e da deteção corporal.

O projeto permitiu igualmente consolidar conhecimentos nas áreas de Inteligência Artificial, Visão por Computador, Desenvolvimento Android, Processamento Digital de Imagem e Engenharia de Software. Durante a sua execução foram enfrentados diversos desafios técnicos, nomeadamente relacionados com integração de bibliotecas, otimização de desempenho, processamento em tempo real e compatibilidade entre diferentes tecnologias. A resolução destes problemas contribuiu para uma melhor compreensão das limitações e potencialidades dos sistemas de Human Pose Estimation em dispositivos móveis.

A fase experimental permitiu ainda comparar diferentes abordagens de deteção de pose humana, verificando que o MediaPipe Pose Landmarker apresentou melhor desempenho para execução em tempo real quando comparado com o YOLO Pose, oferecendo uma combinação equilibrada entre velocidade de processamento, estabilidade visual e facilidade de integração em aplicações Android. Adicionalmente, foi possível calcular ângulos articulares a partir dos landmarks detetados pelo modelo, demonstrando o potencial da Human Pose Estimation para aplicações de análise biomecânica e avaliação de movimento.

De forma geral, os objetivos principais do projeto foram alcançados, tendo sido desenvolvido um protótipo funcional capaz de demonstrar a viabilidade da utilização de Human Pose Estimation on-device como ferramenta de apoio à prática de exercício físico. Os resultados obtidos evidenciam o potencial desta tecnologia para aplicações de treino desportivo, análise biomecânica e monitorização do movimento humano, constituindo uma base sólida para futuras evoluções do sistema.

Bibliografia

- [1] MediaPipe Team. *MediaPipe Pose Landmarker Documentation*. Google, 2025.
- [2] Bazarevsky, V. et al. *BlazePose: On-device Real-time Body Pose Tracking*. Google Research, 2020.
- [3] Ultralytics. *YOLO Pose Documentation*. Ultralytics, 2025.
- [4] Uhlich, S. et al. *OpenCap: Human Movement Dynamics from Smartphone Videos*. PLOS Computational Biology, 2023.
- [5] TensorFlow Team. *MoveNet Documentation*. Google TensorFlow, 2025.
- [6] OpenMMLab. *MMPose Documentation*. OpenMMLab, 2025.
- [7] OpenCV Team. *OpenCV Documentation*. Open Source Computer Vision Library, 2025.
- [8] Google. *Android Developers Documentation*. Android Developers, 2025.
- [9] Google. *CameraX Documentation*. Android Developers, 2025.
- [10] JetBrains. *Kotlin Documentation*. JetBrains, 2025.
- [11] Postlmayr, A.; Cosman, P. (2025). *LiFT: Lightweight Fitness AI-Powered Exercise Correction and Proposal*. Elsevier.
- [12] Vaidya, V.; Navaneetha, U. (2025). *AI-Powered Exercise Correction and Accessible Fitness Solutions Using Human Pose Estimation*. IEEE.
- [13] Men, M.; Wei, M.; Kaushik, M.; Kandala, M. (2024). *Proposal and Validation of a New AI-Based Posture Correction System*. Springer.
- [14] Mahita, V.; Vignesh, G. S. (2024). *AI-Based Posture Correction and Real-Time Exercise Analysis Using Human Pose Estimation*. IEEE.
- [15] Vijay, J.; Ashutosh; Singh, K.; Khushdeep (2024). *AI-Enabled Real-Time Exercise Monitoring Using Human Pose Estimation*. IEEE.
- [16] Ajay, L.; Vidyadevi, G.; Biradar, C.; Chandu, M. (2023). *AI Tool as a Fitness Trainer Using Human Pose Estimation*. IEEE.
- [17] Ajay, L.; Vidyadevi, G.; Biradar, C.; Chandu, M. (2023). *Human Pose Estimation Using AI Trainer*. IEEE.
- [18] Singh, V.; Atharva, P. (2022). *trAIner: An AI Fitness Coach*. IEEE.
- [19] Taware, G.; Kharat, R.; Kien, N. P. (2022). *AI-Based Workout Assistant and Motion Analysis*. IEEE.
- [20] Choudhary, S.; Kumar, M. (2025). *YOLOv11-Powered Real-Time Multi-User Exercise Monitoring*. IEEE.
- [21] Sideridou, M. (2024). *Towards Automating Personal Exercise Monitoring Using BlazePose*. MDPI.
- [22] Sowmia, K. R. (2024). *An Artificial Intelligence Approach to Personal Training Systems*. Springer.
- [23] Difini, G.; Miranda, G. (2022). *A Movement Analysis Application Based on Human Pose Estimation*. ACM Digital Library.
- [24] Woo, Y.; Jeong, H. (2025). *Exercise Assessment Based on Human Pose Estimation and Relative Phase for Real-Time Remote Exercise System*. ResearchGate.
- [25] Mercadal-Baudart, C. et al. (2024). *Exercise Quantification from Single Camera View Markerless 3D Pose Estimation*. ScienceDirect.
- [26] Kagdi, M.; van der Haar, D. (2025). *LiftMate: Gym Exercise Posture Correction and Classification*. ScienceDirect.
- [27] Lambricht, N.; Englebert, A.; Pitance, L.; Fiset, P.; Detrembleur, C. (2024). *Quantifying Performance and Joint Kinematics in Functional Tasks Crucial for Anterior Cruciate Ligament Rehabilitation Using Smartphone Video and Pose Detection*. ScienceDirect.
- [28] Salehi, M.; Taheri, A.; Choi, S.; Kim, J. H. (2026). *Evaluation of a Markerless Motion Capture to Measure 3D Joint Kinematics During Occupational Lifting Tasks Using Mobile Devices*. ScienceDirect.

- [29] Zoeller, C. S.; Niessner, C.; Fleps, M.; Klein, T.; Hanssen-Doose, A.; Burchartz, A.; Woll, A.; Stein, T. (2026). *Video-Based Motion Capture Smartphone Apps for Testing Human Motor Performance Skills: Scoping Review*. ScienceDirect.
- [30] Iqbal, M. T. B.; Mostafa, M. T.; Ahmed, M. T.; Fahim, M. F.; Ahmed, M. S.; Ahamad, A.; Islam, K. R.; Ryu, B.; Song, G.; Hossain, M. Z. (2026). *MobiPhysio: A 2D Video Dataset of Physiotherapy Exercises for AI-Driven Assessment and Monitoring*. ScienceDirect.
- [31] Uhlich, S. D.; Falisse, A.; Kidziński, Ł.; Muccini, J.; Ko, M.; Chaudhari, A. S.; Hicks, J. L.; Delp, S. L. (2023). *OpenCap: Human Movement Dynamics from Smartphone Videos*. PLOS Computational Biology.